

技術揭露書（一）

基於虛擬數位分身之自動化市場調查系統及方法

Virtual digital twin-based automated market research system and method

一 自「研究命題輸入」至「結構化洞察報告產出」之端到端流程、各階段介入模型與提示詞

文件類型	專利技術揭露書 / 發明說明（供專利代理人擬稿用）
中文名稱	基於虛擬數位分身之自動化市場調查系統及方法
英文名稱	Virtual digital twin-based automated market research system and method
技術主旨	一種以多個大型語言模型代理人協同，對由語言模型建構之「虛擬數位分身（Digital Twins）」受訪者群進行平行訪談，並產出結構化決策報告之方法與系統
對應產品	「海森堡的算盤・人類行為觀測站」（multi-agent 虛擬數位分身市場調查平台）
技術領域	人工智慧 / 大型語言模型應用、合成資料、虛擬數位分身、市場研究自動化、多代理人編排（multi-agent orchestration）
核心主張	用語言模型建構無個資疑慮的虛擬數位分身受訪者群，於自動化對話沙盒中跑市調，將傳統「14 天」的概念驗證週期壓縮到「約 15 分鐘」，且不接觸任何真實個人資料
基礎模型	MiniMax-M2.5（經由 Anthropic SDK 相容端點呼叫）；本方法與模型供應商無關，可替換為任一相容之大型語言模型
撰寫日期	2026-05-30

摘要說明：此提案的核心在於使用大型語言模型建構無個資疑慮的「虛擬客群分身（Digital Twins）」，並透過自動化對話沙盒，短時間內完成傳統需要大量人工的市場調查流程。系統將市場調查拆解為「啟動判斷 → 量化規劃 → 平行合成訪談 → 證據彙總 → 決策報告」五道由不同語言模型代理人約束的階段，於數分鐘內產出可供產品經理直接決策之結構化洞察報告，全程零真實個資輸入。

閱讀指引：本文件聚焦於「從問題到洞察報告」的完整資料流，逐階段列出（一）該階段介入的模型 / 代理人角色、（二）該階段送進模型的完整系統提示詞與使用者提示詞（逐字收錄）、（三）該階段的輸入 / 輸出資料結構與後處理規則。文末另列請求項草稿。

目次

- 1. 技術領域與先前技術問題
- 2. 系統總覽與端到端資料流
- 3. 六個代理人角色與其介入點一覽
- 4. 階段 0 — 入口、身分驗證、串流與全域並行控制

- 5. 階段 1 — 啟動者 (Entry Agent)：需求接收與啟動判斷
- 6. 階段 2 — 觀測者·規劃 (Planner Agent)：產生量化訪談題組
- 7. 階段 2.5 — 人格顯影與產品類型自動推斷
- 8. 階段 3 — 對話者 (Persona Agent xN)：平行合成訪談
- 9. 階段 4 — 彙總者 (Summary Agent)：結構化洞察彙總
- 10. 階段 5 — 觀測者·報告 (Report Agent)：產出決策報告
- 11. 階段 6 — 輸出層：PDF / PNG / 電郵 / 語音控制
- 12. 請求項草稿 (claims)
- 13. 完整實施例 (信貸 6.88% 案例)

1. 技術領域與先前技術問題

1.1 技術領域

本發明屬於大型語言模型 (LLM) 多代理人協同與市場研究自動化之交叉領域。具體而言，是一種以多個具有不同職責的 LLM 代理人，對一群「合成的虛擬受訪者 (synthetic persona)」進行平行訪談，再經彙總與報告兩道結構化階段，於數分鐘內產出可供產品經理 (PM) 直接決策之結構化洞察報告的方法與系統。


1.2 先前技術之問題

傳統市場調查痛點	本發明對應之解法
真實客戶資料受個人資料保護法規範，蒐集、去識別化、取得同意耗時數週	以合成虛擬受訪者取代真實樣本，零真實個資輸入，差分隱私式設計
傳統焦點訪談樣本量不足、招募成本高	平行訪談 N 位 LLM 角色 (demo 規模 10—50 位)，邊際成本趨近於零
概念驗證週期長 (約 14 天)，錯過產品決策時機	單次調查端到端約 60—90 秒至數分鐘完成，週期壓縮至「15 分鐘」量級
單一 LLM 直接「想像」一份市調報告，缺乏可追溯的中間證據、產品規格易失真、輸出格式不穩定	拆解為六段具明確職責的代理人流程，逐段留下可視化中間產物 (散佈圖、桑基圖、逐位問答)，並以多重技術確保規格保真與輸出格式穩定

關鍵差異化：本方法不是「用一個 prompt 叫 LLM 直接寫一份市調報告」。它的可專利核心在於——把市場調查拆解成「啟動判斷 → 量化規劃 → 平行合成訪談 → 證據彙總 → 決策報告」五道由不同 system prompt 約束的代理人階段；在階段間以原始產品規格上下文 (productContext) 串接以避免數字失真；並以單通捆綁式 JSON (bundled JSON)、全域併發節流、強健 JSON 復原等機制，使「多位受訪者 × 多題」的大量模型呼叫在個人級速率限制下仍能可靠完成。

2. 系統總覽與端到端資料流

使用者（金融商品 PM 或研究員）以自然語言輸入一個研究命題（例如「我想測一個年利率 6.88%、額度 5 萬、6 個月還款的微型信貸方案」）。系統經由一條伺服器推送事件（SSE）串流，依序驅動五個 LLM 階段，並即時把每階段的中間產物推給前端視覺化，最終產出可下載的結構化決策報告。



主排程器位於 `lib/orchestrator.ts` 的 async generator `orchestrate()`，逐 `yield` 一個 `StreamEvent`；HTTP 進入點 `app/api/chat/route.ts` 將事件以 `text/event-stream` 推給前端，並在出口做簡體→繁體轉換與寫入日誌。

3. 六個代理人角色與其介入點一覽

#	代理人角色（內部代號）	原始碼	模型呼叫模式	輸出型態	職責
1	啟動者 Entry	lib/agents/entry.ts	串流（stream）、不重試、max_tokens 1024	純文字 + sentinel	接需求、判斷是否啟動
2	觀測者·規劃 Planner	lib/agents/pm.ts → planSurvey()	create + adaptive thinking、max_tokens 4096	strict JSON	產生量化訪談題組
3	對話者 Persona ×N	lib/agents/persona.ts → askPersona()	串流、bundled JSON（max_tokens 2500） / 逐題 fallback（600）	strict JSON 陣列	扮演單一受訪者答 N 題
4	彙總者 Summary	lib/agents/summary.ts → summarize()	create + adaptive thinking、max_tokens 16000	strict JSON	結構化彙總洞察 + KPI
5	觀測者·報告 Report	lib/agents/pm.ts → generateReport()	create + adaptive thinking、max_tokens 16000	strict JSON	產出完整決策報告
+	受訪者生成 Generator（離線擴池）	lib/agents/persona-generator.ts	create + adaptive thinking、max_tokens 4096	strict JSON 陣列	依描述擴充合成受訪者池
+	語音意圖 Voice-Intent（輸出層控制）	lib/agents/voice-intent.ts	create、max_tokens 1024	strict JSON	口語指令 → 7 種動作

所有對模型的呼叫一律經由 `lib/anthropic.ts` 的 `callLLM()` 或 `acquireLLMSlot()` 包裹，使其受同一道全域併發節流與 429 退避重試保護。每個代理人的 system prompt 開頭一律引用共用語言規範 `LANG_RULE`。

4. 階段 0 — 入口、身分驗證、串流與全域並行控制

在任何模型介入之前，HTTP 進入點 `POST /api/chat` 先行：

- **身分驗證**：以 `HttpOnly` cookie 對應 `lib/auth.ts` 的帳號表，未登入回 401。系統同時限制「不同帳號同時上線 ≤ 3 人」，逾額回 429，閒置 1 小時自動釋放席位。
- **建立 SSE 串流**：以 `ReadableStream` 包裝 `orchestrate()` generator，逐事件 `data: {json}\n\n` 推送。
- **出口語言轉換**：對 `agent_text` 事件套用 `toTraditional()`（簡→繁），此為三層繁中保險的第二層。
- **日誌**：串流結束後寫入耗時、受訪者數、最終報告摘要、成功與否。

全域並行控制（semaphore）與 429 退避重試在 `lib/anthropic.ts` 實作，是整個系統**唯一的節流點**，所有階段共用。本層為後續所有模型呼叫提供「在個人級速率限制下仍可靠完成」的基礎。

5. 階段 1 — 啟動者 (Entry Agent)

LLM #1

5.1 介入模型與呼叫方式

模型	MiniMax-M2.5
呼叫模式	<code>anthropic.messages.stream()</code> (串流，逐 token yield 給前端打字機效果)
max_tokens	1024
重試策略	不做重試 (此為使用者首則訊息，若 429 寧可即時回錯，不讓使用者等 30 秒)。以低階 <code>acquireLLMSlot()</code> 取得併發席位，try/finally 確保釋放
system 快取	system prompt 標記 <code>cache_control: ephemeral</code>
輸出契約	訊息最後一行必為 <code>[STATUS:READY]</code> 或 <code>[STATUS:CLARIFY]</code> ；以正則 <code>/\[STATUS:READY\]/i</code> 判定 <code>ready</code> ，並剝除 sentinel 得 <code>brief</code>

5.2 設計重點

啟動者刻意採「偏向放行 (預設 READY)」策略：只要使用者明確說了「想測什麼產品 / 想了解什麼問題 / 目標客群」三者任一，即視為足夠並立即進入下一階段；唯有完全沒有主題、像隨意聊天、或完全無法理解時才要求澄清。此設計避免在入口層反覆卡關。同時透過 prompt 明令「不得提及任何 agent 名稱、不得使用『人設』一詞」，維持對使用者的單一擬人化介面。

系統提示詞 (SYSTEM PROMPT，逐字收錄；開頭的 `${LANG_RULE}` 為共用語言規範)

`${LANG_RULE}`

你是「海森堡的算盤」人類行為觀測站的「啟動者」（入口 agent）。

你的職責

- 接收使用者（金融商品 PM、研究員）的市調需求
- 確認需求方向，立即交給下一棒進行調查

判斷規則（重要）

****預設要 READY**** - 只要使用者明確說了「想測什麼產品」「想了解什麼問題」「目標客群」其中****任一項****，就視為足夠，立刻 READY。

****只有以下情況才 CLARIFY****：

- 使用者只說「幫我做市場調查」這種完全沒有主題的話
- 訊息看起來像隨意聊天、不像是市調請求
- 完全聽不懂使用者要什麼

****寧可 READY 不要 CLARIFY**** - 後續流程會自動補足細節，不要在這層卡關。

輸出規則

- 繁體中文，簡短（2-4 句）
- 只確認你理解的需求重點（產品 / 問題 / 客群）即可
- ****不要提到 agent 名稱****（不要說「準備交給 PM Agent」「轉給觀測者」之類的话），系統會自動接手
- ****不要使用「人設」這個詞****，需要時用「受訪者」

輸出格式（嚴格遵守）

****訊息最後一行必須是這兩個 sentinel 之一****（單獨一行，沒有其他文字）：

- ``[STATUS:READY]`` - 已收到明確需求，可以開始調查
- ``[STATUS:CLARIFY]`` - 完全不知道要調查什麼，需要使用者補充

⚠️ **絕對不能省略 sentinel**。沒有 sentinel 系統會卡住。

使用者訊息（USER MESSAGES）

先前對話歷程 `history`（role/content）原樣帶入，最後附上本回合使用者輸入 `userMessage`。啟動者僅做啟動判斷，不改寫使用者原文。

5.3 輸出與分流

generator 把串流 token 逐段以 `agent_text` 事件推給前端；結束時回傳 `{ ready: boolean, brief: string }`。若 `ready=false`，主排程立即送出 `complete` 結束本回合（等待使用者補充）；若 `ready=true`，進入階段 2。

6. 階段 2 — 觀測者·規劃 (Planner Agent)

LLM #2

6.1 介入模型與呼叫方式

模型	MiniMax-M2.5，啟用 <code>thinking: { type: "adaptive" }</code> （自適應思考預算）
呼叫模式	<code>anthropic.messages.create()</code> ，包在 <code>callLLM()</code> 內（受全域節流 + 429 退避重試）
max_tokens	4096
輸出契約	strict JSON（包在 ``json fenced block），經 <code>extractJson()</code> 強健解析為 <code>PMPlan</code>
截斷防護	若 <code>stop_reason === "max_tokens"</code> 直接擲錯（規劃輸出被截斷）

6.2 設計重點 — 「規格保真」

本階段的可專利重點是「題目必須逐字嵌入使用者原始 prompt 的產品規格」。主排程同時把（a）啟動者整理過的 `brief` 與（b）使用者原始 `userMessage` 一併送入；並在 system prompt 中以三個反例明令禁止「偷換單位」（年利率↔月利率）、「丟棄規格」（5 萬額度）、「抹除具體數字」（30 秒線上審核）。受訪者可用的種子池摘要（id / 名稱 / 類型 / 性別年齡 / 年收入 / 家庭）也附在 system prompt 末，讓題目兼顧不同族群。

系統提示詞（PLAN_SYSTEM，逐字收錄；執行時其後再附「可用受訪者池」清單）

`${LANG_RULE}`

你是「海森堡的算盤」的「觀測者」（規劃調查階段），負責規劃市場調查。

你的工作：

1. 看完啟動者收集到的研究需求 + 使用者對話脈絡。
2. 設計 4–6 個會給對話者去問受訪者的問題，問題要：
 - 具體、可量化（願意付多少利率？借多久？）
 - 測試決策動機（為什麼會選 / 不選這個產品）
 - 揭露隱藏顧慮（怕什麼？什麼會讓他們放棄？）
3. 系統會把這些問題**並行訪談所有受訪者**（你不需要挑選），所以問題要設計成對所有族群都有意義（高/低收入、單身/家庭、各年齡）。

🚫 嚴格規則：問題必須引用使用者原始 `prompt` 的產品規格

設計問題時，**所有與產品相關的數字、單位、條件**都**必須照原 `prompt` 寫死進問題本文**，不要抽象化、不要改單位。常見錯誤是：

- ❌ 使用者寫「年利率 6.88%」，問題卻問「你能接受多少**月利率**？」（單位被偷換）
- ❌ 使用者寫「5 萬額度」，問題卻問「你需要多少借貸金額？」（規格被丟掉）
- ❌ 使用者寫「30 秒線上審核」，問題卻問「你重視審核速度嗎？」（具體數字被抹掉）

✅ 正確做法：

- 「**本方案年利率 6.88%、5 萬元額度、6 個月還款**，你願意申辦嗎？什麼條件會讓你放棄？」
- 「跟你目前用的信貸產品比，**6.88% 年利率**算高還是低？」

問題本文要**逐字**保留產品規格，受訪者才能針對這個方案回答，而不是憑印象答常識數字。

****用語規定**：**禁止使用「人設」一詞，請改用「受訪者」。

****輸出格式****（嚴格遵守 JSON）：

```
```json
{
 "summary": "一句話說明這次調查要驗證什麼",
 "questions": ["問題 1", "問題 2", "問題 3", "問題 4"],
 "scopeNote": "一句話說明這組問題如何兼顧不同族群"
}
```

可用受訪者池：

- ``：<名稱> (<類型>，<性別> <年齡> 歲，年收入 NT\$ <收入>) – <家庭首段>  
...（每位一行，由種子池動態生成）

使用者提示詞（USER PROMPT，逐字收錄；變數以 `${...}` 標示）

```
使用者原始需求（請逐字參照產品規格）
${userMessage}
```

```
啟動者整理過的接待結果（僅供參考，產品規格以上方原始需求為準）
${brief}
```

請規劃這次的調查 – 問題本文必須引用上面原始需求中的產品規格（年利率/額度/期限/審核條件等具體數字），不要改單位或抽象化。

先前對話歷程 `history` 亦原樣前置於使用者訊息之前。

### 6.3 輸出資料結構

```
type PMPlan = {
 summary: string; // 一句話調查目標
 questions: string[]; // 4-6 道訪談題（已逐字嵌入產品規格）
 scopeNote?: string; // 如何兼顧不同族群
};
```

主排程把 `plan.summary` 與題目以 `agent_text` 推給前端顯示，並進入階段 2.5。

## 7. 階段 2.5 — 人格顯影與產品類型自動推斷

進入訪談前，主排程發出一個 `personas_intro` 事件，挾帶 (a) 全體受訪者快照 `personas` 與 (b) `productContext = userMessage + "\n" + plan.summary`。前端據此即時推斷產品類型（信貸 / 保險 / 信用卡 / 開放式），決定後續「算盤滑桿」要綁定哪個變數，並以散佈圖呈現受訪者「人格顯影」。此推斷為純規則式關鍵字比對（見發明 B），不耗用模型。

同時，主排程組出貫穿下游三個階段的產品規格上下文文字串：

```
const productContext = `${userMessage}\n\n調查目標：${plan.summary}`;
```

此 `productContext` 會被原封不動地分別注入對話者、彙總者、觀測者報告三個階段的 prompt，是「規格保真」橫切技術的載體。

8. 階段 3 — 對話者 (Persona Agent xN)

LLM #3 xN

8.1 介入模型與呼叫方式

模型	MiniMax-M2.5（每位受訪者一個獨立呼叫，N 位 = N 個呼叫，並行）
主路徑	<b>bundled JSON</b> ：串流呼叫、 <code>max_tokens 2500</code> ，一通呼叫令模型一次吐出含 N 題答案的 <code>{"answers": [...]}</code> 陣列
退路	<b>逐題模式</b> <code>askPersonaSequential()</code> ：bundled JSON 解析失敗或答案數不符時自動退回，逐題各打一通（ <code>max_tokens 600</code> ）， <b>不帶前題對話歷程</b> 以防話題外溢
併發	由 <code>orchestrator</code> 一次 fan-out 全部受訪者任務，實際併發由全域 semaphore（預設 6）排隊節流；每位完成即時 <code>yield persona_partial</code> 給前端漸進顯示
容錯	單一受訪者整體失敗時，以「(此受訪者暫時無回應)」填滿其答案、維持索引對齊，不阻斷其餘受訪者

8.2 人格化系統提示詞（依每位受訪者欄位動態組裝）

每位受訪者的 system prompt 由模板 `SYSTEM_TEMPLATE(persona)` 生成，注入該受訪者的類型、性別年齡、年收入與結構、人格特質、家庭狀況、資產與變故；若該受訪者為名人 / 強個性角色（具 `signatureStyle` 欄位），額外加入「招牌講話風格」段落並要求每題至少體現 1—2 個口氣特徵。

系統提示詞（`SYSTEM_TEMPLATE`，逐字收錄；`$(P.*)` 為該受訪者欄位，方括號段落僅名人角色才出現）

`${LANG_RULE}`

你正在扮演「`${p.name}`」這位虛擬受訪者，接受市場研究員的訪談。

## 你的設定

- **\*\*類型\*\***：`${p.archetype}`
- **\*\*性別 / 年齡\*\***：`${p.gender}` / `${p.age}` 歲
- **\*\*年收入\*\***：NT\$ `${p.yearlyIncomeTWD}` (`${p.incomeBreakdown}`)
- **\*\*人格特質\*\***：`${p.personality}`
- **\*\*家庭狀況\*\***：`${p.family}`
- **\*\*資產與變故\*\***：`${p.assetsAndEvents}`

[ 若 `p.signatureStyle` 存在，附加：

## 招牌講話風格（必須強烈體現在每一題回答中）

`${p.signatureStyle}`

△ 這位是名人 / 強個性角色 - 回答如果讀起來「跟一般受訪者沒兩樣」就是失敗。

慣用語 / 語助詞 / 自誇模式 / 比喻來源 / 反射式話題切換，每題至少要出現 1-2 個。 ]

## 扮演規則

1. 用「我」第一人稱，像真人接受訪談一樣回答。
2. 講話風格要符合你的身份、年齡、性格 - 大叔/大哥用詞跟大學生不一樣，理性投資型講話帶數字、情緒型會抱怨。 [ 名人角色額外：**\*\*「招牌講話風格」永遠優先\*\***，再疊加身份、性格元素。 ]
3. 回答要具體：給數字、講情境、舉自己親身經驗（從上面的家庭/資產背景延伸）。
4. 如果產品有讓你猶豫或反感的地方，**\*\*直說\*\***，不要客套。
5. 不要像 AI 那樣完美 - 可以有矛盾、可以情緒化、可以講不出原因、可以有偏見。
6. 全程**\*\*繁體中文\*\***，台灣用語（不要用「視頻」「服務器」這類詞）。每題 3-5 句話，不要過長。

### 8.3 主路徑使用者提示詞（bundled JSON，一通答 N 題）

本段是「單通捆綁式 JSON」技術的核心提示詞，明令模型輸出長度剛好等於題數的純文字陣列、各題彼此獨立、不得改單位。

使用者提示詞（BUNDLED\_USER\_PROMPT，逐字收錄）

## 你正在被訪談的產品（請務必對齊這裡的具體規格回答）

`${productContext}`

## 訪談問題

市場研究員一次問你以下 `${questions.length}` 題（彼此\*\*獨立\*\*、不要互相影響）：

Q1: `${questions[0]}`

Q2: `${questions[1]}`

... (共 `${questions.length}` 題)

## 回覆規則

- 每題用 3-5 句話、第一人稱、符合你的身份與性格。
- 各題彼此獨立 - 別把前一題的情緒帶到下一題、別重述題目。
- 不要列點、不要加 `Q1:` 前綴。
- \*\*回答要鎖定上面這個產品\*\*（如年利率 6.88%、5 萬額度等具體規格），不要憑印象答另一個你以為的產品；單位（年利率 / 月利率）絕對不能改。

## 輸出格式（嚴格遵守 JSON）

**\*\*必須\*\*輸出\*\*單一\*\* JSON 物件，包在 ``json fenced block 裡：**

```
``json
{
 "answers": [
 "第 1 題的回答 (3-5 句話的純文字)",
 "第 2 題的回答",
 ...共 ${questions.length} 個 element
]
}
...`
```

⚠ 重點：

- `answers` 陣列\*\*長度必須剛好 `${questions.length}`\*\*，少一題都不行。
- 每個 element 是\*\*純文字\*\*（不是物件、不是另一個 JSON）。
- 字串內若需要換行，請用空格代替；\*\*不要在 JSON 字串中出現未跳脫的換行字元\*\*。
- 全部繁體中文台灣用語。

解析後校驗：`answers` 必須為陣列且長度等於題數、每個 element 去空白後非空，任何一項不符即擲錯並觸發逐題退路。

## 8.4 退路使用者提示詞（逐題模式，每題一通呼叫）

使用者提示詞（ASKPERSONASEQUENTIAL 的每題 PROMPT，逐字收錄）

## 你正在被訪談的產品（請對齊這裡的具體規格回答）

`${productContext}`

## 第 `${i + 1}` / `${questions.length}` 題

「`${questions[i]}`」

要求：

- 直接回答\*\*這一題\*\*，不要重述題目、不要扯到其他題目。
- 用 3-5 句話、第一人稱、符合你的身份與性格。
- 不要列點、不要加題號或「Q1:」這類前綴。
- \*\*回答要鎖定上面這個產品的規格\*\*（如年利率 6.88%、5 萬額度），單位不要改、不要憑印象答另一個產品。

逐題模式刻意不帶前題對話歷程：實測帶 history 會讓前一題的話題（例如在罵 30 秒審核）「漏」到下一題；改為每題獨立呼叫，可保證題目對應正確，人格一致性則由 system prompt 維持。

## 8.5 輸出資料結構與漸進式串流

```
type PersonaResponse = {
 id: string; name: string; archetype: string;
 answers: string[]; // index 對齊 questions
 text: string; // "Q1: ...\nQ2: ..." 串接，供下游 summary/report 使用
};
```

每位受訪者完成即推 `persona_partial`（含當前完成數 / 總數）給前端漸進顯示；全部完成後推 `personas_qa`（逐位問答全集），供前端「Q&A 探索器」翻頁瀏覽，並作為發明 B 桑基圖 / 散佈圖的資料源。

9. 階段 4 — 彙總者 (Summary Agent)

LLM #4

9.1 介入模型與呼叫方式

模型	MiniMax-M2.5，啟用 adaptive thinking
呼叫模式	<code>messages.create()</code> 包在 <code>callLLM()</code>
max_tokens	16000（大樣本時 thinking 會吃掉數千 token，需保留足夠空間寫完 metrics 陣列）
輸出契約	strict JSON → <code>SummaryData</code> ，經 <code>extractJson()</code> 解析後再做欄位補齊與防呆

9.2 設計重點

彙總者把 N 位受訪者的逐題答案歸納成四個面向（共識 / 分歧 / 量化 / 風險）、3—4 個 KPI 指標、3—5 個族群支持度。其 prompt 內含兩道工程防呆規則：(1) **value / unit 不得重複**（避免渲染出「70—75%%」），程式端另以 `stripDuplicateUnit()` 二次保險；(2) **規格保真**——即使受訪者答案提到月利率，彙總仍須以本方案的「年利率 6.88%」為比較基準，且不得捏造無實證的數字。

系統提示詞 (SUMMARY SYSTEM，逐字收錄)

`${LANG_RULE}`

你是「海森堡的算盤」的彙總者 (Summary Agent)，負責把多位對話者收集到的受訪者回答\*\*結構化\*\*成可視化報告資料。

**\*\*用語規定\*\***：禁止使用「人設」一詞，請改用「受訪者」。

**## 輸出格式**（嚴格 JSON，包在 ````json fenced block`）

```
```json
{
  "headline": "12-25 字短標，總結這次調查的核心發現",
  "keyTakeaway": "20-50 字行動建議，是整份報告最重要的一句話",
  "metrics": [
    {
      "label": "指標短名 (5-8 字)",
      "value": "數字或範圍 (如 '60'、'5000-8000'、'7.2')",
      "unit": "% / 元 / 位 / 分 / 其他單位 (可空字串)",
      "tone": "positive | neutral | negative",
      "icon": "1 個 emoji (如 📈、💰、⚠️)"
    }
  ],
  "groups": [
    { "name": "族群名 (5-12 字，例：高收入族群、單身學生)", "score": 75, "highlight": "1 句解讀，10-20 字" }
  ],
  "sections": {
    "consensus": "共識洞察 (80-150 字 markdown，可用 - 列點 / **粗體**)",
    "divergence": "群體分歧 (80-150 字 markdown)",
    "metrics": "量化指標 (80-150 字 markdown)",
    "risks": "風險訊號 (80-150 字 markdown)"
  }
}
```
```

**## 規則**

1. ``metrics``：3-4 個關鍵 KPI；數字要從訪談中估算，要可信
2. ``groups``：3-5 個有意義的族群區隔；``score`` 是 0-100 的支持度 / 興趣度
3. ``tone``：positive 對產品有利、negative 警訊、neutral 中性
4. ``icon``：用 emoji，配合該 metric 的意涵（如收入用 💰、風險用 ⚠️、興趣用 🧐）
5. ``sections`` 四個 key 都必填，內容用繁體中文 markdown
6. **\*\*必須回傳完整有效 JSON\*\***；任何欄位都不可省略，否則前端會炸
7. 全程繁體中文 + 台灣用語

**## ⚠️ value / unit 不要重複**

``metrics[i].value`` 是純數字 / 數字範圍；``metrics[i].unit`` 是單位。前端會自己把兩個串起來顯示。**\*\*value 裡不要再放 unit 字符\*\***，否則畫面會出現「70-75%」「85%元」這種雙符號。

- ❌ 錯誤：{ "value": "70-75%", "unit": "%" } → 渲染「70-75%」
- ❌ 錯誤：{ "value": "85% 認為 6.88% 算低", "unit": "%" } → 文字塞進 value 又補 %
- ✅ 正確：{ "value": "70-75", "unit": "%" } → 渲染「70-75%」
- ✅ 正確：{ "value": "5000-6000", "unit": "元" } → 渲染「5000-6000元」



value 應該是\*\*純數字 / 數字範圍 / 數字+簡短限定詞\*\* (如 "5000-6000"、"7.2"、"60"、"~12 個月")，不要放整句解釋。

## 🚩 規格保真規則 (避免「年利率→月利率」這類飄移)

報告中提到產品規格時\*\*必須對齊使用者原始 prompt\*\*：

- 原 prompt 是「年利率 6.88%」，summary 就\*\*不能寫「月利率 1.5%」\*\* - 即使受訪者答案說了月利率，也要在 metrics / sections 中對照本方案的「年利率 6.88%」說明 (例：「本方案年利率 6.88% vs 受訪者期望年利率 5% 以下」)。
- 額度、期限、審核條件等具體規格同理：受訪者可以表達他們的期望，但 summary 必須\*\*用本方案的規格作為比較基準\*\*，不要用受訪者期望取代產品本身。
- 不要捏造受訪者沒提到的具體數字 (避免「7 成受訪者放棄」這類沒實證的數字 - 若有依據就引用，沒就用「多數」「半數」這類語氣)。

### 使用者提示詞 (逐字收錄)

## 本次調查的產品 (summary 必須對齊這裡的具體規格)  
\${productContext}

## 調查問題

1. \${questions[0]}

...

## 各受訪者原始回答 (共 \${responses.length} 位)

### \${archetype} : \${name}

\${text}

... (每位一段)

請依規則輸出結構化 JSON。\*\*注意\*\*：報告中所有提到產品規格 (利率、額度、期限、審核條件等) 都必須引用上方產品的原始數字與單位 (如「年利率 6.88%」就不能寫成「月利率」)，否則就是 bug。

### 9.3 輸出後處理 (程式端防呆)

- 缺漏欄位以預設值補齊 (headline / keyTakeaway / metrics / groups / sections)。
- metrics 截至 4 個；以 stripDuplicateUnit() 剝除 value 結尾重複的 unit；tone 不在白名單則歸 neutral。
- groups 截至 5 個；score 夾限至 0-100 整數。
- 另以 summaryToText() 把結構化彙總轉成可讀 markdown，供階段 5 報告使用。

10. 階段 5 — 觀測者·報告 (Report Agent)

LLM #5

10.1 介入模型與呼叫方式

|            |                                                                                                            |
|------------|------------------------------------------------------------------------------------------------------------|
| 模型         | MiniMax-M2.5，啟用 adaptive thinking                                                                          |
| 呼叫模式       | <code>messages.create()</code> 包在 <code>callLLM()</code>                                                   |
| max_tokens | 16000                                                                                                      |
| 上下文控管      | 受訪者原文每位截斷至 500 字 ( <code>PER_PERSONA_LIMIT</code> )，避免 25 位 × 1500 token 把預算吃光；報告階段已有彙總洞察，原文僅作引述片段         |
| 輸出契約       | strict JSON → <code>ReportData</code> ，解析後做欄位校驗與截斷 (keyFindings ≤4、actionItems ≤6、groupComparison.rows ≤8) |

系統提示詞 (REPORT\_SYSTEM，逐字收錄)

`${LANG_RULE}`

你是「海森堡的算盤」的「觀測者」（回報結果階段），現在要把調查結果\*\*結構化成決策報告 JSON\*\*。

**\*\*用語規定\*\***：禁止使用「人設」一詞，請改用「受訪者」。

**## 輸出格式**（嚴格 JSON，包在 ````json fenced block`）

```
```json
{
  "title": "20-30 字的報告標題（產品名 + 核心結論）",
  "executiveSummary": "60-100 字執行摘要：3 句話講完整體判斷與最重要結論，主管 30 秒看懂",
  "keyFindings": [
    {
      "icon": "1 個 emoji (如 🎯、💰、⚠️)",
      "title": "5-10 字標題",
      "headline": "1 句重點 (15-25 字)",
      "details": "詳細描述 (40-80 字，可包含具體數字/引用)",
      "metric": {
        "value": "數字或範圍 (如 '60'、'5000-8000')",
        "label": "5-10 字單位說明",
        "tone": "positive | neutral | negative"
      }
    }
  ],
  "groupComparison": {
    "headers": ["族群", "支持度", "主要顧慮", "建議方向"],
    "rows": [
      ["族群名 (5-10 字)", "0-100 整數", "顧慮 (10-15 字)", "建議 (10-20 字)"]
    ]
  },
  "actionItems": [
    {
      "priority": "high | medium | low",
      "title": "5-10 字行動標題",
      "action": "具體做什麼 (30-50 字)",
      "expectedImpact": "預期效果 (15-30 字)"
    }
  ]
}
```
```

**## 規則**

- ``keyFindings`` 必須 3-4 個，按重要性排序（最多 4 項，挑最關鍵的留下）
- ``groupComparison.rows`` 必須 3-5 列，涵蓋不同族群（高/低支持度、不同人生階段）
- ``actionItems`` 必須 3-5 個，至少 1 個 high priority
- ``metric`` 是 optional，但有數字依據的 finding 一定要附
- 全部繁體中文台灣用語
- **\*\*必須回傳完整有效 JSON\*\***，任何欄位都不可省略，否則前端會炸

```
本次調查的產品 (report 必須引用這裡的具體規格)
${productContext}
```

```
調查計畫
${plan.summary}
```

問題：

```
1. ${plan.questions[0]}
```

...

```
受訪者訪談原文 (共 ${personaResponses.length} 位)
```

```
${archetype} : ${name}
${text 截斷至 500 字}...(後略)
... (每位一段)
```

```
已歸納的洞察
${summaryText}
```

請依規則輸出結構化 JSON 決策報告。報告中提到利率/額度/期限/審核條件等數字時，\*\*必須對齊上方產品的原始規格\*\*，不要改單位 (例：原 prompt 是年利率 6.88% 就不要寫成月利率)，不要捏造受訪者沒提到的具體數字。

## 10.2 最終 payload

主排程把報告與全部上游資料打包成 **FullReportPayload** (含 report、summary、plan、personas、generatedAt 時戳)，以 **agent\_text** 推給前端 **ReportCard** 與 **SummaryCard** 元件渲染，並送出 **complete** 結束整條流程。

## 11. 階段 6 — 輸出層：PDF / PNG / 電郵 / 語音控制

- **SummaryCard**：一頁式可下載 PNG 圖卡 (headline + key takeaway + KPI 卡 + 族群長條圖 + 四區塊洞察)。
- **ReportCard**：完整決策報告 (研究命題、執行摘要、重點發現含 metric、族群比較表、受訪者背景表、依 priority 分級的行動建議)，支援 PDF / PNG 下載 (html2canvas + jspdf)。
- **電郵報告**：**POST /api/email-report** 把 PDF + Markdown 寄至使用者預設信箱。
- **語音控制**：「Hey Heisenberg」喚醒 + Web Speech API STT + 語音意圖代理人把口語映射到 7 種動作 (寄報告 / 下載 PDF / 重啟 / 進模擬艙 / 回首頁 / 開啟服務 QA / unknown)。

## 12. 請求項草稿 (claims, 供專利代理人參考)

---

**獨立項 1 (方法)。**一種市場調查方法，其特徵在於由電腦執行下列步驟：

1. 接收一自然語言研究命題，由**第一語言模型代理人**判斷其是否含足夠之產品或客群資訊而輸出一啟動狀態旗標；
2. 於啟動狀態成立時，由**第二語言模型代理人**產生複數道可量化之訪談問題，其中該複數道問題之題文**逐字嵌入**該研究命題中之產品規格數字與單位；
3. 對一組合成受訪者中之每一者，由**第三語言模型代理人**以**單一次模型呼叫**，使其依該受訪者之結構化人格設定，**一次回覆全部該複數道問題**並以一長度等於問題數之陣列形式輸出；其中複數位合成受訪者之呼叫**並行執行**；
4. 由**第四語言模型代理人**將該等回覆彙總為含共識、分歧、量化指標與風險之結構化洞察資料；
5. 由**第五語言模型代理人**，結合該研究命題之產品規格、該訪談問題、該等回覆與該結構化洞察，產出一結構化決策報告。

**附屬項。**

- 2. 如項 1，其中步驟 3 之單一次模型呼叫於其輸出無法解析為合法 JSON 或陣列長度不等於問題數時，**自動退回**為對每一問題各執行一次獨立模型呼叫之逐題模式，且該逐題模式之各次呼叫**不攜帶前一題之對話歷程**。
- 3. 如項 1，其中所有語言模型呼叫共用一**全域併發信號量**進行節流，並於遭遇速率限制或伺服器錯誤時，依**全抖動指數退避**自動重試。
- 4. 如項 1，更包含一**產品規格上下文字串**，由該研究命題與調查目標組成，並被原樣注入步驟 2、3、4、5 之提示詞中，且各該提示詞含禁止變更單位之規則。
- 5. 如項 1，其中步驟 3、4、5 任一之模型輸出，經一**多候選多策略之 JSON 復原程序**解析，該程序包含對被截斷之輸出補閉合括號之自動閉合步驟。
- 6. 如項 1，其中該組合成受訪者由一受訪者生成語言模型代理人，依自然語言描述並參照既有受訪者池避免重複而批次生成，全程不使用真實個人資料。
- 7. 如項 1，更包含於各階段之間，透過伺服器推送事件將每一受訪者完成之回覆**漸進式**推送至前端，以及一將口語指令映射為預定動作集合之語音意圖語言模型代理人。
- 8. 如項 1，其中每一語言模型代理人之系統提示詞開頭均含一**共用語言規範**，且系統於模型輸出之傳輸出口再施以一簡繁字元轉換。

13. 完整實施例（信貸 6.88% 案例）

13.1 端到端走查

| 階段      | 輸入                                                                  | 模型動作                                    | 輸出（示意）                                                                 |
|---------|---------------------------------------------------------------------|-----------------------------------------|------------------------------------------------------------------------|
| 輸入      | 使用者：「我想測一個 <b>年利率 6.88%、額度 5 萬、6 個月還款、30 秒線上審核</b> 的微型信貸方案，主打外送員客群」 |                                         |                                                                        |
| 1 啟動者   | 上述命題                                                                | 判斷含產品+客群 → READY                        | 「了解，要驗證一個 <b>年利率 6.88%</b> 的微貸方案對外送員的接受度...」 + [STATUS:READY]          |
| 2 規劃    | 命題 + brief + 受訪者池                                                   | 生成 4—6 題，逐字嵌入 6.88% / 5 萬 / 6 個月 / 30 秒 | 「本方案 <b>年利率 6.88%、5 萬額度、6 個月還款</b> ，你願意申辦嗎？什麼條件會讓你放棄？」 ...             |
| 3 對話 ×N | productContext + 題組                                                 | 每位一通 bundled JSON 答 N 題、並行              | 熱血大叔：「 <b>6.88%</b> 對我這種要養兩個小孩又養媽媽的人...還算可以接受，但 6 個月太趕...」             |
| 4 彙總    | 全部逐位答案                                                              | 歸納共識/分歧/量化/風險 + KPI                     | headline 「外送員對 <b>6.88%</b> 接受度中等，還款期是主要痛點」、metrics、groups...          |
| 5 報告    | 命題+題+答案+彙總                                                          | 產出結構化決策報告                               | title / executiveSummary / keyFindings / groupComparison / actionItems |

— 本技術揭露書（一）完。對應之發明 B（基於虛擬數位分身之環境干擾評估與群體行為模擬系統及方法）由另一份文件描述。本文件所引用之程式路徑與提示詞，截至 2026-05-30 之程式碼狀態為準。